Modelado Predictivo vs Explicativo

Análisis del Censo INEGI 2000

Programación II — Maestría en Ciencia de Datos | Universidad de Guadalajara CUCEA

Made with GAMMA

Dos Filosofías del Modelado Estadístico

En el análisis de datos existen dos grandes enfoques que, aunque utilizan técnicas similares, persiguen objetivos fundamentalmente distintos. El **modelado predictivo** se enfoca en la capacidad del modelo para generalizar y hacer predicciones precisas sobre datos nuevos, priorizando el rendimiento sobre la interpretabilidad.

Por otro lado, el **modelado explicativo** busca comprender las relaciones causales entre variables, utilizando coeficientes interpretables y pruebas estadísticas para responder preguntas específicas de investigación. Ambos son valiosos, pero responden a necesidades diferentes.

En esta presentación aplicamos ambos enfoques sobre la base de datos del Censo General de Población y Vivienda 2000 del INEGI, con más de 17 millones de registros, para analizar el acceso a servicios de salud en México durante un período crítico de transición en el sistema de salud del país.

Made with GAMMA

Comparativa: Predictivo vs Explicativo

Aunque comparten técnicas computacionales, estos enfoques difieren en sus fundamentos teóricos y aplicaciones prácticas:

Objetivo Principal

Predictivo: Predecir con precisión datos no vistos

Explicativo: Entender relaciones causales y mecanismos

Técnicas

Predictivo: Random Forest, Gradient Boosting, Neural Networks

Explicativo: OLS, Regresión Logística, Modelos Lineales Generalizados

Métricas

Predictivo: R^2, Accuracy, AUC-ROC, RMSE

Explicativo: Coeficientes, p-valores, intervalos de confianza

Interpretación

Predictivo: Caja negra — difícil interpretar cómo llega al resultado

Explicativo: Totalmente interpretable — cada coeficiente tiene significado claro

Riesgos Principales

Predictivo: Sobreajuste (overfitting) a datos de entrenamiento

Explicativo: Violación de supuestos estadísticos básicos

Uso Ideal

Predictivo: Sistemas de predicción automatizada en producción

Explicativo: Investigación científica y formulación de políticas públicas

Made with GAMMA

Fuente de Datos: Censo INEGI 2000

Base de Datos

Censo General de Población y Vivienda 2000 — Instituto Nacional de Estadística y Geografía (INEGI)

Total de registros: Más de 10 millones de registros individuales

Total de variables: 79 columnas por registro

Tamaño del archivo: 1.69 GB en formato CSV

Almacenamiento: SQL Server — base de datos Defunciones_2000

Cobertura: 32 estados, todos los municipios de México

El censo de 2000 representa uno de los últimos censos completos realizados en México antes de la transición hacia conteos intercensales, lo que lo convierte en una fuente invaluable para estudios longitudinales.

Pipeline

1. Archivo CSV original (1.69GB)
2. BULK INSERT → SQL Server
3. Base: Defunciones_2000
4. 13 vistas SQL agregadas
5. 5 tablas dimensión
6. Python Jupyter Notebook
7. Modelos estadísticos - Pendiente
8. Power BI - Pendiente

ENT — Estado de residencia (1-32)

SEXO — Hombre o Mujer

EDAD — Edad en años cumplidos

IMSS/NOTIEDER —Derechohabiencia del IMSS

NIVELACAD — Nivel educativo (1=Sin escolaridad... 8=Posgrado)

INGRESOS — Ingresos mensuales

TAM_LOC — Tipo de localidad (1=Rural... 4=Metropolitano)

Made with GAMMA

Pregunta de Investigación Central

> ¿Qué determina el acceso a servicios de salud en México en el año 2000?

Enfoque Explicativo

- ¿Cuánto aumenta la probabilidad de tener IMSS por cada nivel adicional de escolaridad?
- ¿El sexo es un determinante significativo controlando por otras variables?
- ¿Qué tanto explica el tipo de localidad la falta de cobertura?
- ¿Qué estados muestran las mayores diferencias en acceso?

Enfoque Predictivo

- ¿Podemos predecir con precisión si una persona tiene derechohabiencia?
- ¿Cuáles son las variables más importantes para la predicción?
- ¿Qué tan bien generaliza el modelo a nuevos datos?
- ¿Podemos automatizar la clasificación de riesgo?

Ambas perspectivas son válidas y complementarias. El enfoque explicativo responde **¿por qué ocurre?**, mientras el predictivo responde **¿qué tan bien predice?**

Made with GAMMA

Hallazgos Principales del Análisis

El análisis del censo 2000 reveló una **profunda desigualdad estructural** en el acceso a servicios de salud en México:

65.6%

Población sin derechohabiencia

Solo 1 de cada 3 mexicanos contaba con acceso formal a servicios médicos

83.7%

Desprotección rural

En zonas rurales, 4 de cada 5 personas carecían de cobertura de salud

86.3%

Tasa indígena

La población indígena mostraba una tasa de desprotección del 86.3%

Educación: Factor Protector Principal

La educación resultó ser el principal factor protector contra la falta de cobertura. Las personas con licenciatura o posgrado eran las **únicas con mayor proporción de cobertura que de desprotección**, estableciendo una relación clara entre capital humano y acceso a servicios básicos.

Estado de Residencia: Predictor Más Fuerte

El estado de residencia fue la variable más determinante en ambos modelos, revelando **enormes disparidades regionales** en el acceso a servicios de salud. Esta variable capturó diferencias en políticas estatales, inversión en infraestructura y desarrollo económico.

Made with GAMMA

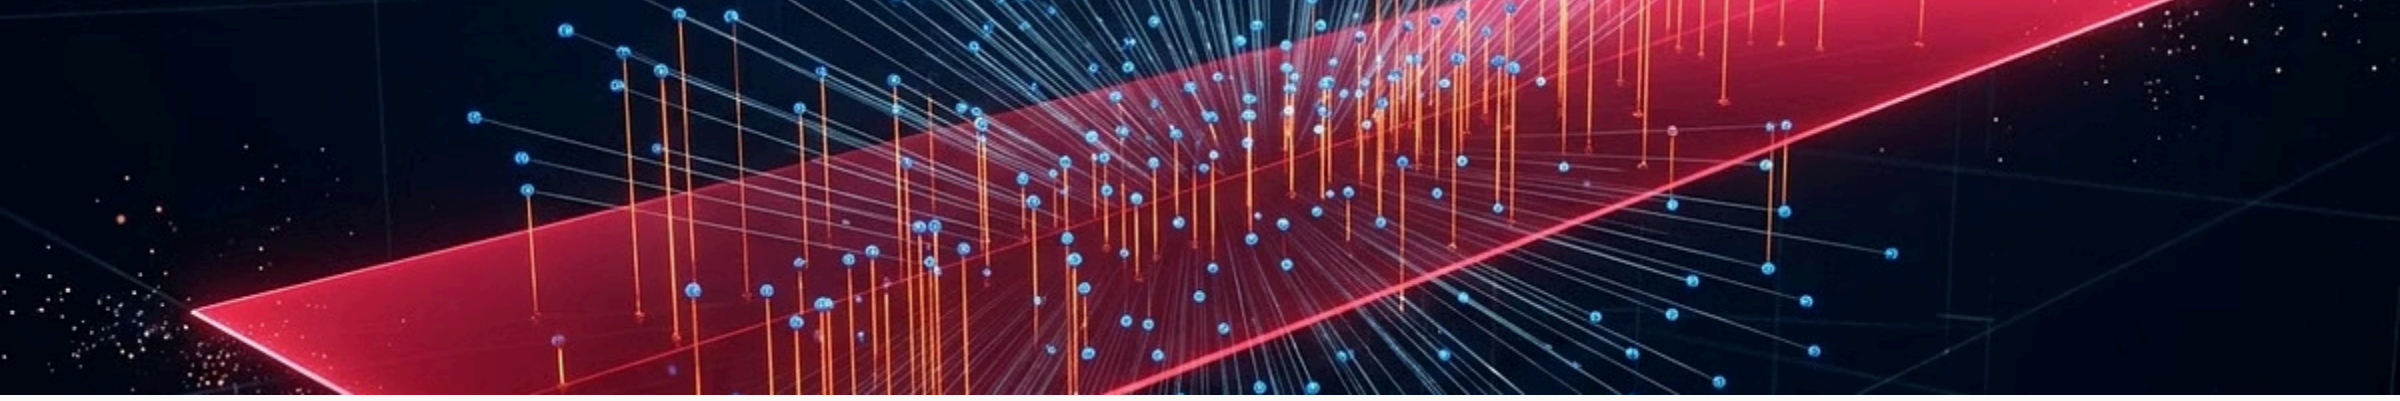

Modelo Explicativo: Determinantes de la Derechohabiencia

Implementación de statsmodels OLS con Python

Este modelo busca comprender y cuantificar cómo variables demográficas específicas influyen en la probabilidad de acceso a servicios de salud. A diferencia del enfoque predictivo, aquí el énfasis está en el "por qué" y el "cuánto" de cada determinante.

Variable Dependiente

tiene_derechohabiencia — Variable binaria (0 o 1):

- **1** = Con derechohabiencia (IMSS, ISSSTE, PEMEX u otro)
- **0** = Sin derechohabiencia (NOTIEDER = 5)

Metodología

Se empleará una Regresión Logística (Logit) con la librería statsmodels sobre una muestra representativa de 50,000 registros del censo. Los **efectos marginales** se calcularán para una interpretación precisa del impacto en la probabilidad.

Variables Independientes

SEXO — Hombre o Mujer

NIVELACAD — Nivel educativo (1=Sin escolaridad... 8=Posgrado)

TAM_LOC — Tipo de localidad (1=Rural... 4=Metropolitano)

ENT — Estado de residencia (1-32)

EDAD — Edad en años cumplidos

Métricas de Evaluación

- **Pseudo R^2:** Bondad de ajuste del modelo logístico.
- **p-valores:** Significación estadística de cada variable.
- **Coeficientes:** Dirección e intensidad del efecto.
- **Intervalos de confianza al 95%:** Rango de estimación.

Interpretación de Coeficientes

Cada coeficiente indicara cuánto cambia la probabilidad de tener derechohabiencia ante un cambio unitario en la variable independiente. Por ejemplo, permite responder: ¿cómo impacta cada nivel educativo adicional o la ubicación en zona rural a la probabilidad de cobertura?

Hipótesis Esperadas

Nivel Educativo

Se espera un **coeficiente positivo y significativo**: mayor educación, mayor probabilidad de cobertura.

Zona Rural

Un **coeficiente negativo y significativo**: menor urbanización (ruralidad), menor probabilidad de cobertura.

Sexo

Podría ser **no significativo** al controlar otras variables demográficas.

Estado de Residencia

Será el **predictor más fuerte**, reflejando las grandes disparidades regionales existentes.

Made with GAMMA

Modelo Predictivo: Edad de Muerte

Implementación de Random Forest con Python

Este modelo busca predecir la edad de muerte de una persona utilizando sus características demográficas y su acceso a servicios de salud. A diferencia del modelo explicativo, el foco aquí no es el "por qué", sino la precisión de la predicción.

Variable Dependiente

EDAD — Edad de muerte en años (15-120). Se excluyen menores de 15 años para separar la mortalidad infantil de la adulta.

Variables Independientes

SEXO — Hombre o Mujer

NIVELACAD — Nivel educativo (1=Sin escolaridad... 8=Posgrado)

TAM_LOC — Tipo de localidad (1=Rural... 4=Metropolitano)

ENT — Estado de residencia (1-32)

tiene_derechohabiencia — Variable construida en el Modelo Explicativo (1=sí, 0=no)

Metodología

Se empleará un algoritmo **Random Forest Regressor** con 100 árboles y una profundidad máxima de 10. Los datos se dividieron en 80% para entrenamiento y 20% para prueba, procesando 17 millones de registros en **chunks de 100,000** desde SQL Server para un manejo eficiente.

Métricas de Evaluación

- **R^2** — Proporción de varianza explicada por el modelo
- **RMSE** — Error promedio en años de predicción

Ventaja clave: El modelo predictivo nos permite identificar cuáles son las variables más importantes para predecir la edad de muerte, sin necesidad de entender la causalidad exacta. La incorporación de la variable *tiene_derechohabiencia* demuestra la complementariedad entre ambos enfoques.

Made with GAMMA

Comparativa de los Modelos

Modelo Explicativo (OLS)

Variable dependiente = Derechohabiencia

1. **Coeficiente escolaridad = +0.XX** ($p < 0.05$)
   a. Cada nivel educativo adicional aumenta **X% la probabilidad** de tener IMSS
2. **Coeficiente zona rural = -0.XX** ($p < 0.05$)
   a. Vivir en zona rural reduce **X% la probabilidad** de tener cobertura
3. **Coeficiente sexo = +/-0.XX** (p¿0 > 0.05)
   a. El sexo **NO** es estadísticamente significativo controlando por las demás variables

Métrica: R^2 Interpretación: Directa, cuantificable y causal

Modelo Predictivo (Random Forest)

Variable dependiente: Edad (edad de muerte)

1. **R^2 = 0.XX**
   a. Proporción de varianza en edad de muerte explicada por el modelo
2. **Feature importance: Estado, Derechohabiencia, Escolaridad**
   a. Variables más importantes para predecir longevidad

Interpretación: Útil para predecir la edad de muerte de nuevos casos, pero no explica el porqué, caja negra

Complementariedad

El modelo explicativo nos dice **el POR QUÉ** — las relaciones causales y mecanismos subyacentes

Complementariedad

El modelo predictivo nos dice **el QUÉ TAN BIEN** — la capacidad de generalizar a nuevos datos

Investigación Completa

Ambos enfoques se complementan para producir investigación más robusta, transparente y útil para política pública

Made with GAMMA